

Téma 4: Částečný problém vlastních čísel ①

úloha: $\|A \in \mathbb{C}^{n \times n}, |\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n| \geq 0\}$

→ najdi aproximaci měřítka vlastních čísel a vektoru (např. největší - odhad $\|A\|$, Google Page Rank problem; nejménší - regulárita A ; $\langle \lambda_{\min}, \lambda_{\max} \rangle$ - odhad $\text{d}(A)$; approximace A maticí menší hodnoty; ...)

4.1 MacCorma' metoda = dvojice (λ_1, v_1)

- odhad jednoho vlastního vektora (dominantního)

• speciální případ:

- nechť $|\lambda_1| > |\lambda_2|$, tj. dominantní vlastní vektor je jednoznačně určen

- nechť A má nížní systém vlastních vektorů, tj. je diagonálně rozdělen

$$A = SDS^{-1}, S = [s_1, \dots, s_n], D = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix}$$

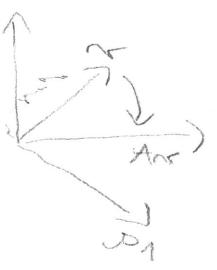
odvození: $v \in \mathbb{C}^n, v \neq 0 \dots$ lib. vlastní vektor

→ co se stane, když li množit $A \times v$?
koefficienty v v bázi vlastních vektorů A

$$\exists c_1, \dots, c_n \in \mathbb{C}: v = c_1 s_1 + c_2 s_2 + \dots + c_n s_n / A.$$

$$Av = c_1 A s_1 + c_2 A s_2 + \dots + c_n A s_n =$$

$$= c_1 \lambda_1 s_1 + c_2 \lambda_2 s_2 + \dots + c_n \lambda_n s_n$$


Výška největší \Rightarrow vzdálenost v do směru s_1

\Rightarrow bestreichen $s_1, \tilde{s}_1, A(s_1), \dots$ ②

$$A_{\tilde{s}_1} = c_1 \tilde{s}_1 + c_2 \tilde{s}_2 + \dots + c_m \tilde{s}_m / \tilde{s}_1$$

$$\frac{1}{\tilde{s}_1} \cdot A_{\tilde{s}_1} = c_1 \tilde{s}_1 + \underbrace{[c_2 \left(\frac{\tilde{s}_2}{\tilde{s}_1} \right) \tilde{s}_2 + \dots + c_m \left(\frac{\tilde{s}_m}{\tilde{s}_1} \right) \tilde{s}_m]}_{\tilde{s}_1}$$

$$\Rightarrow \boxed{\left(\frac{1}{\tilde{s}_1} \right) A_{\tilde{s}_1}} \xrightarrow{s_1 \rightarrow 0} c_1 \tilde{s}_1 \text{ f. und } c_1 \neq 0 \text{ } \tilde{s}_1 \text{ ist nicht } 0$$

jein Skalar

\Rightarrow chc. nl. vektor normieren \Rightarrow gleich

$$\boxed{\frac{1}{\|A_{\tilde{s}_1}\|} \cdot A_{\tilde{s}_1} \xrightarrow{s_1 \text{, da } \|s_1\|=1 \text{ a. s. f.}} \text{vlastl vektor } \tilde{s}_1}$$

apr. nl. ēsle:

idea: $As_1 = \lambda_1 s_1 \Rightarrow \lambda_1 = s_1^* A s_1$

\Rightarrow je -l. $\tilde{s}_1 \approx s_1$, f. $\mu := \frac{\tilde{s}_1^* A \tilde{s}_1}{\tilde{s}_1^* \tilde{s}_1} \approx \lambda_1$

def: ēsle $\mu := \frac{\tilde{s}_1^* A \tilde{s}_1}{\tilde{s}_1^* \tilde{s}_1}$ nennen Rayleigh-
höhr f. d. approxim. nl. ēsle.

algorithmus: vstup: $A, \tilde{s}_1 \neq 0, m^{\text{max. # iterací}}$

$\tilde{s}_1 := \tilde{s}_1 / \|\tilde{s}_1\|$
vystup: \tilde{s}_m, μ_m - apr. nl. píru

for. $k = 1, \dots, m$ do

$\tilde{s}_k := \frac{A \tilde{s}_{k-1}}{\|\tilde{s}_{k-1}\|}$

$\tilde{s}_k := \tilde{s}_k / \|\tilde{s}_k\|$

$\mu_k := \tilde{s}_k^* A \tilde{s}_k$

end

Keďže: Nechť $A \in \mathbb{C}^{n \times n}$ diagonálizovateľná, ③

$| \lambda_1 | > | \lambda_2 | \dots > | \lambda_p | > | \lambda_{p+1} | \dots > | \lambda_n |$ a $v \in \mathbb{C}^n$ kolore, $\tilde{v} \neq v \neq 0$. Pak pre maximálnu metodu platí, že
 $v \xrightarrow{\text{def.}} s$, $\|v\| = 1$, $\text{Span} \{s\} = \text{Span} \{v\}$,
 $v \xrightarrow{\text{def.}} \tilde{v}$.

Konvergenci násobku lineárnej súčiestnosti $\frac{\lambda_2}{\lambda_1}$

D: platí \Rightarrow pre dôkaz konstrukce \square

stabilita: nap. náhľad - 1x násobení
 $\Rightarrow A \sim +$ inéach

- zámer - náhľadame len v_1, v_2 a hľadáme
- regulárnost kdež. rávnože na tom, či je dobré je λ_1 oddelené od ostatných
t.č. a čo je blízke je $v \rightarrow 0$ je s_1 (regulárnosť c_1 opäť c_2, \dots, c_n)

Záver: $v \neq s_1$ \Rightarrow práv vektormi súčiestnosti
(\sim - rel. náhľadný vektor) nede se
nagenerovať dôkaz súčiestnosti \Rightarrow FTA

• obecný prípad: $| \lambda_1 | = \dots = | \lambda_p | > | \lambda_{p+1} | \dots > | \lambda_n |$

$\lambda_1 = \dots = \lambda_p \dots$ met. konverguje k rel. vekt.
zámer - met. mohie divergovať

$$\Sigma: A = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, v = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \Rightarrow Av = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \Rightarrow A^2v = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \dots$$

Záver: analog. následky platí i pre A
nediagonálizovateľnou - mnohem
súčasťí dôkazu

• modifikace možn. met: Inverzní mech. met. (4)

článek Ang. 3.2: nejménší n.č. a n. řešení

$$\begin{array}{ccc} A & \Rightarrow & A^{-1} \\ \begin{matrix} a_1, \dots, a_m \\ \sim_1, \dots, \sim_m \end{matrix} & \Rightarrow & \begin{matrix} 1/a_1, \dots, 1/a_m \\ \sim_1, \dots, \sim_m \end{matrix} \end{array} \quad \text{dom. n.č. } A^{-1}$$

\Rightarrow aplikuj možn. met. na A^{-1} , tj.
řešit \Leftrightarrow nahradit řešení řešením soustavy rovnic $A \mathbf{x} = \mathbf{b}$

- řešit (s) nej. řešit met. $\mathbf{x} = A^{-1} \mathbf{b}$!

4.2 Krylovovy prostor

úloha: článek approximace n.č. řeš. řeš. A

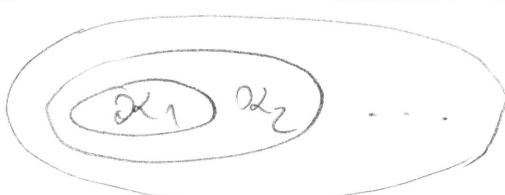
\rightarrow řešení celého prostoru $\{ \mathbf{b}, A\mathbf{b}, \dots, A^{m-1}\mathbf{b} \}$

def: $A \in \mathbb{C}^{n \times n}$ regul., $\mathbf{r} \in \mathbb{C}^n$, $\mathbf{r} \neq 0$, $m \geq 1$.

Pok. $\mathcal{K}_m(A, \mathbf{r}) = \{ \mathbf{b}, A\mathbf{b}, \dots, A^{m-1}\mathbf{b} \}$ je m. krylov.

Krylovový prostor matice A vzhledem k \mathbf{r} .

$$\mathbb{C}^n:$$



$$\mathcal{K}_1 \subseteq \mathcal{K}_2 \subseteq \dots \subseteq \mathbb{C}^n$$

$$\dim(\mathcal{K}_m(A, \mathbf{r})) \leq m \leq n$$

ozn: $\rho(A)$ je: \mathbf{r} - n. řeš. $A \Rightarrow A\mathbf{r}$ je l. řeš. \mathbf{r} - n. řeš. $\Rightarrow \dim(\mathcal{K}_m(A, \mathbf{r})) = 1$

ozn: $d(A, \mathbf{r}) := \min\{m: \dim(\mathcal{K}_m) = \dim(\mathcal{K}_{m+1})\}$

... řešení řešenou řeš. vzhledem
k matice A

Platf.: 1, $d(A, \sim) \leq m$ (5)
 2, $\dim(\mathcal{K}_m(A, \sim)) = m, m=1, \dots, d(A, \sim)$
 3, $\dim(\mathcal{K}_m(A, \sim)) = d(A, \sim), m \geq d(A, \sim)$

D: 1, \dots triv. 2, \sim definice $d(A, \sim)$
 3, A^{\sim} je lin. kombinac $\sim, \dots, A^{d-1} \sim \Rightarrow$
 $\Rightarrow \exists \lambda_i, i=0, \dots, d-1: A^{\sim} = \sum_{i=0}^{d-1} \lambda_i A^i \sim \mid A$
 $\Rightarrow A^{d+1} = \sum_{i=0}^{d-1} \lambda_i A^i \sim = \sum_{i=1}^{d-1} \lambda_{i-1} A^i \sim + \lambda_d A^d \sim =$ dosadit
 $= \sum_{i=0}^{d-1} \beta_i A^i \sim \Rightarrow A^{d+1} \in \mathcal{K}_d(A, \sim)$ □

deslede: $\mathcal{K}_1(A, \sim) \subset \dots \subset \mathcal{K}_d(A, \sim) = \mathcal{K}_{d+1}(A, \sim) = \dots$
 $\Rightarrow \mathcal{K}_m(A, \sim), m \geq d(A, \sim)$ je A -invariantní

Vypočet báze $\mathcal{K}_m(A, \sim)$: $P_p: m \neq d(A, \sim)$

\rightarrow Krylovova báze $\sim, A\sim, \dots, A^{m-1}\sim$ je množství nezávislých vektorů (velkým hrom. k. sl. některé, řadě jsou množ. shore závislé)
 \rightarrow dle ON bázi, nejméně množství A^k

• Arnoldiho proces:

\equiv speciálně upravený Gram-Schmidt

\Rightarrow ex. se varianční ale CGS, MGS, když se stabilizuj, paralelizuj, ...
 - počítá ON bázi $\mathcal{K}_m(A, \sim)$

odvození:

6

(6)

dvození:

$$\begin{array}{c}
 \text{[n]} \xrightarrow{\text{množ}} \text{[n1]} \xrightarrow[\text{A}]{\text{množ}} \text{[n1, An1]} \xrightarrow{\text{množ}} \text{[n1, n2]} \xrightarrow{\text{množ}} \text{[n1, n2]} \xrightarrow{\text{množ}} \\
 \text{[n1, n2, An2]} \xrightarrow[\text{A}]{\text{množ}} \text{[n1, n2, n3]} \xrightarrow{\text{množ}} \dots
 \end{array}$$

OG

Kerok $\lambda=1$: $\alpha_1 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \dots \text{span} \{ \alpha_1 \} = \text{span} \{ \alpha_1 \}$

$$\underline{\text{krok } k=2} : \tilde{w}_2 := A_{22} - (w_1^* A_{21}) w_1$$

$$\tilde{w}_2 := \tilde{w}_2 / \|\tilde{w}_2\| \quad \text{span}\{\tilde{w}_1, \tilde{w}_2\} = \\ = \text{span}\left\{ \tilde{w}_1, \tilde{w}_2 \right\}$$

$$\text{Krok } k=3: \tilde{v}_3 = \text{Arc}_2 - (\text{Arc}_1^* \text{Arc}_2) v_1 - (\text{Arc}_2^* \text{Arc}_1) v_2$$

$\tilde{v}_3 := \tilde{v}_3 / \| \tilde{v}_3 \|$ ○ Gerebt

Breit messen mit $\overline{A_{\text{xx}}}$ und $\overline{A_{\text{yy}}}$.

$$\text{span}\{r_1, A^1r_1, A^2r_1\} = \text{span}\{r_1, Ar_1, A^2r_1\} = \\ A(\text{span}\{r_1, r_2, r_3\})$$

D: $A_{\text{in}} \in \text{span}\{a_1, a_2\} \Rightarrow A(A_{\text{in}}) \in \text{span}\{Aa_1, Aa_2\}$

$$\text{obenr: } \tilde{r}_{\text{ext}} := \text{Arg}_2 - \sum_{i=1}^n (r_i^* \text{Arg}_2) r_i$$

$$(\star) \quad \alpha_{n+1} := \tilde{\alpha}_{n+1} / \|\tilde{\alpha}_{n+1}\|, \quad n=1, 2, \dots, m-1$$

Lemma: Verfaren $\approx_{1,-}$ zum Genera-
ne \approx_{red}^* ist ordnungstreu
a $\text{Span}\{\approx_{1,-}\} = \text{Knt}(A, \approx)$.

D: flexne & hensbruce

10

(7)

algoritmus : vstup: A, \sim, m
 (MGS varianta) výstup: \sim_1, \dots, \sim_m .. ON báze $K(A)$

$$\sim_1 = \sim / \| \sim \|$$

for $k=1, 2, \dots, m-1$ do

$$m := \text{rank } \sim$$

for $i=1, \dots, k$ do

$$h_{i,k} := \sim_i^* m$$

$$m := m - h_{i,k} \sim_k$$

end

$$h_{k+1,k} := \| \sim_k \|$$

if ($h_{k+1,k} = 0$) then STOP

else $\sim_{k+1} := \sim / h_{k+1,k}$

end

! DLOUHÉ
REKURENCE

\equiv množ. rek.
 Až se OG
 počí vžem
 předchozím
 místem řešení, jehož
 dosáhne $k+1$ (výsledek
 dosáhnutí $k = d(A, \sim)$)

charakteristiky : užit. výhodou - 1x můžeme řešit
z hlediska iterace, dletočné rek.

- jádře - uhládáme \sim_1, \dots, \sim_m
- OG se radikálně dobrě
- cena iterace \propto rychle rostoucí

OGu : $V_k := \begin{bmatrix} \text{ON báze} \\ \sim_1, \dots, \sim_k \end{bmatrix} \in \mathbb{C}^{n \times k}$, OG koeficienty $\in \mathbb{C}$

$$H_k := \begin{bmatrix} h_{11} & \dots & h_{1k} \\ h_{21} & \dots & h_{2k} \\ \vdots & \ddots & \vdots \\ 0 & \dots & h_{k1} & h_{kk} \end{bmatrix} \in \mathbb{C}^{k \times k} \dots \text{horní Hessenbergova matice}$$

$\in \mathbb{R}$, norming > 0

$$H_{k+1,k} := \begin{bmatrix} H_k \\ \hline 0 \cdot 0 \cdot h_{k+1,k} \end{bmatrix} \in \mathbb{C}^{(k+1) \times k}, \quad k=1, \dots, m-1$$

8

Lemma: Nechť $m \leq d(A, v)$. Pak pro matici $V_a, H_a, H_{a+1,a}, a=1, \dots, m-1$ generované Arnoldůvým procesem platí:

$$\begin{aligned} 1) \quad AV_a &= V_{a+1} H_{a+1,a} & \text{matica} \\ 2) \quad AV_a &= V_a H_a + h_{a+1,a}^{\text{CTR}} V_{a+1,a} & \text{matica} \\ 3) \quad V_a^* A V_a &= H_a & \text{odvození 1} \end{aligned}$$

$$\begin{bmatrix} 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix}$$

$$\begin{aligned} D: \quad (*) &\Rightarrow h_{a+1,a} V_{a+1} = A V_a - \sum_{i=1}^a h_{a+1,i} V_i, \quad i=1, \dots, m-1 \\ &\Rightarrow A V_a = \sum_{i=1}^a h_{a+1,i} V_i + h_{a+1,a} V_{a+1} \Rightarrow \\ &\Rightarrow A \cdot [v_1, \dots, v_a] = [v_1, \dots, v_{a+1}] \cdot H_{a+1,a} \Rightarrow 1) \\ 1, \Rightarrow 2, \text{ sice.} \end{aligned}$$

$$AV_a = V_a H_a + h_{a+1,a} V_{a+1,a}^T / V_a^*.$$

$$V_a^* A V_a = H_a + h_{a+1,a} \underbrace{V_a^* V_{a+1,a}}_{= \sum_{i=1}^a h_{a+1,i} V_i, i=1, \dots, a}^T \quad \square$$

Závěr: Řechneme, že H_a je sítění operátoru A na prostor $K_a(A, v)$

$$A: \mathbb{C}^m \rightarrow \mathbb{C}^m$$

$$H_a: \mathbb{C}^a \rightarrow \mathbb{C}^m$$

• Lanczosova diagonálnizace: $P_p: A = A^*$

\equiv řešení schématu Arnoldůvým procesem pro matici $A - \cancel{\text{Hermitský}}$, $A \in \mathbb{C}^{n \times n}$

$$H_a = V_a^* A V_a = V_a^* A^* V_a = H_a^* \Rightarrow H_a \text{ - hermit.}$$

Nové: $\begin{cases} h_{i+1,i}^{\text{NORMY}} \in \mathbb{R} \\ h_{i,i} \in \mathbb{R} \end{cases} \Rightarrow H_a = \begin{bmatrix} h_{11} & & & & 0 \\ h_{21} & h_{22} & & & \\ \vdots & \vdots & \ddots & & \\ 0 & & & h_{a-1,a} & \\ & & & h_{a-1,a} & h_{aa} \end{bmatrix}_{\text{CTR}}^{n \times n}, \text{ SYMETRICKÁ}$

⑨ důsledek: ON base $\mathcal{K}(A, \mathbf{r})$ je A-HUD
 lze řešit 3-členou rekurzí (tj. orthogonalizace je pro 2-mu předchozímu vektoru), když 1 koeficient máme a předchozího vektoru (normu)

algoritmus: vstup: A, \mathbf{r}, m

(MGS varianta)

$$n_1 = \mathbf{r} / \|\mathbf{r}\|$$

výstup:

$$B_1 := 0, n_0 := 0$$

for $r=1, 2, \dots, m-1$ do

$$n_r := A n_{r-1} - B_{r-1} n_{r-1}$$

$$d_r := n_r^* n_r$$

$$n_r := n_r - d_r n_r$$

$$B_{r+1} := \|n_r\|$$

$$n_{r+1} := n_r / B_{r+1}$$

end

! KRÁTKÉ REKUR
RENCE

ozn: $V_r = \begin{bmatrix} \text{ON base} \\ n_1, \dots, n_r \end{bmatrix}, T_r = \begin{bmatrix} B_1 & B_2 & 0 \\ B_2 & \ddots & B_n \\ 0 & B_n & d_r \end{bmatrix} \in \mathbb{R}^{r \times r}$

$T_{r+1, r} = \begin{bmatrix} T_r \\ 0 \end{bmatrix} \in \mathbb{R}^{(r+1) \times r}, r=1, \dots, m-1$

plán: $\|A V_r = V_{r+1} T_{r+1, r} = V_r T_r + B_{r+1} n_{r+1} e_r^T\|$

Díky
řešení
pro Arnoldiho

$$V_r^* A V_r = T_r, r=1, \dots, m-1$$

poznámká: krátké rek. jsou mimořádne lehčí (konstantní cenu říkání), ale OG se výdile výrazně

4.3 Apretimace sl. Č. na $K_d(A, \nu)$

10

máme: $A \in C_{\mathbb{C}^n}$, regul

vel.: $\nu \in \mathbb{C}^n$, $\nu \neq 0$

zíme: $K_d(A, \nu)$ je A -invariantní \Rightarrow

\Rightarrow specielle ON bází $K_d(A, \nu)$ Am. proc.

\rightarrow jež platí $\boxed{A \nu_d = \nu_d H_d}$

base má podobu A

Lemma: Označme $(\underline{v_i}^{(d)}, \underline{u_i}^{(d)})$, $i=1, \dots, \hat{d}$

platí že $\nu_d H_d$. Tak $(\underline{v_i}^{(d)}, \underline{u_i}^{(d)})$ je

platí že A , $i=1, \dots, \hat{d}$.

D: $\hat{d} = \# \text{ sl. jiné } H_d$, $\hat{d} \leq d$; $i \in \{1, \dots, \hat{d}\}$:

$$AV_d \underline{v_i}^{(d)} = V_d(H_d \underline{v_i}^{(d)}) = V_d(\underline{v_i} \underline{u_i}^{(d)}) =$$

$$\underline{v_i}^{(d)} = \underline{v_i} \cdot \underbrace{V_d \underline{u_i}^{(d)}}_{\hat{d} \times \hat{d}} \Rightarrow A \underline{v_i} = \underline{v_i} \underline{x_i} \quad \square$$

důk: ježli $K_d(A, \nu)$ A -invariantní,
jež máme nejprve sl. jiné A

ALE! obecně sheme apretimaci ν
mentínu ježku iteraci Am. procesu

(d může být záleží, může \approx FPA
designu respektive H_d přesné)

aproximace v.l. ě. v. násled. sk.:

(11)

$$AV_n = V_n H_n + h_{n+1,n} V_{n+1} e_n^T$$

$1 \leq n \leq d$

zku: $(v_i^{(n)}, u_i^{(n)})$, $i=1, \dots, k$ v.l. jazyk H_n

$$\Rightarrow A(V_n u_i^{(n)}) = v_i^{(n)}(V_n u_i^{(n)}) + h_{n+1,n} (e_n^T u_i^{(n)}) v_{n+1}$$

$\underbrace{= x_i^{(n)}}_{=: x_i^{(n)}} \quad \underbrace{= x_i^{(n)}}_{=: x_i^{(n)}} \quad \underbrace{= r_i^{(n)}}_{=: r_i^{(n)}}$

$$|| A x_i^{(n)} = v_i^{(n)} \cdot x_i^{(n)} + r_i^{(n)}, \text{ kde } r_i^{(n)} \text{ je chybá} \\ \text{aproximace}$$

def: Nechť $(v_i^{(n)}, u_i^{(n)})$ je vlastní pár pro H_n ,
 $1 \leq n \leq d$. Dvojice $(v_i^{(n)}, V_n u_i^{(n)}) = (x_i^{(n)}, x_i^{(n)})$
nazveme Ríkem pro matice A .

Vektor $r_i^{(n)} = A x_i^{(n)} - v_i^{(n)} x_i^{(n)} = h_{n+1,n} (e_n^T u_i^{(n)}) v_{n+1}$
nazveme chybou Ríkem pro A .

Jak oběťe approximuj R. jazyk v.l. jazyk A ?

Ježu: Chybá Ríkem pro A splňuje

$$(1) \quad r_i^{(n)} \perp K_n(A, v)$$

$$||r_i^{(n)}|| = h_{n+1,n} |e_n^T u_i^{(n)}|$$

$$D: r_i^{(n)} = \underbrace{h_{n+1,n} (e_n^T u_i^{(n)})}_{\in \mathbb{C}^{n+1} \text{ - vektor}} \cdot v_{n+1} \quad \begin{matrix} \text{if } ||r_i^{(n)}|| = 1 \\ \text{if } r_i^{(n)} = 0 \end{matrix} \Rightarrow \text{true.}$$

Ježu: - měla $||r_i^{(n)}|| \neq 1$ následná approximaci
- oběťe se approximuje obraz $\pi_f(A)$

postup násycení (schema):

(12)

vstup: $A, n \neq 0, m$

výstup: Ritz. páry A

for $k=1, \dots, m-1$ do

proved 1 přidavný krok Arn. procesu k $\bigcup_{k=1}^m H_k$

spocti vl. páry $(\mu_i^{(k)}, v_i^{(k)}) H_k, i=1, \dots, \tilde{k}$

spocti Ritz. vektory $x_i^{(k)} = V_k v_i^{(k)}, i=1, \dots, \tilde{k}$

end

$\lambda_1(A, n)$

$\downarrow H_1$

Ritz. páry

$\lambda_2(A, n)$

$\downarrow H_2$

max. 2 páry

$\lambda_m(A, n)$

$\downarrow H_m$

max. m páry

\equiv ARNOLDIHO METODA APPROXIMACE VL. PÁŘŮ

Záruka: vl. páry H_k bude počítat efektivně,

neboť $k \ll n$ a $H_k = \boxed{0}^T$ má lepší

strukturu (iterační QR algoritmus).

spec. případ A-hermitovská: $P_P: A = A^*$

\rightarrow Arn. proc. nahradíme Lanc. říd.

\equiv LANCZOSOVA MET. APR. VL. PÁŘŮ

\Rightarrow následující náhrada

- bude získat lepší odhad vlastních

$$||AV_k = V_k T_k + B_{k+1} v_{k+1} e_k^T +$$

$(\mu_i^{(k)}, v_i^{(k)}), \dots$ vl. páry T_k

Lemma: $A \in \mathbb{C}^{n \times n}$, $A = A^*$. Pak Ribe. (13)

Für $(\alpha_i^{(k)}, x_i^{(k)})$ speziell lanc. metoden schätzen, da $|\min(\lambda - \alpha_i^{(k)})| \leq \beta_{k+1} \|e_k^T y_i^{(k)}\|$.

D: $A = A^* \Rightarrow \exists$ spkt. zerfall: $A = U D U^*$,
 $D = \begin{bmatrix} \alpha_1 & & \\ & \ddots & \\ & & \alpha_n \end{bmatrix}$, U-unitär

$$\begin{aligned} x_i^{(k)} &= A x_i^{(k)} - (\alpha_i^{(k)} x_i^{(k)}) = U D U^* x_i^{(k)} - (\alpha_i^{(k)} U U^* x_i^{(k)}) = \\ &= U (D - \alpha_i^{(k)} I) U^* x_i^{(k)} \Rightarrow \end{aligned}$$

$$\|x_i^{(k)}\| = \|\underbrace{U(D - \alpha_i^{(k)} I)}_{\text{matrix norm}} \cdot \underbrace{(U^* x_i^{(k)})}_{\text{eine norm}}\| \geq$$

$$\geq \min_{j=1, \dots, n} |\lambda_j - \alpha_i^{(k)}| \cdot \|x_i^{(k)}\|$$

matrix norm \geq element norm

$$\text{matrix } \|x_i^{(k)}\| = \|\underbrace{U x_i^{(k)}}_{\text{matrix norm}}\| = \|x_i^{(k)}\| = 1$$

$$\Rightarrow \min_{j=1, \dots, n} |\lambda_j - \alpha_i^{(k)}| \leq \|x_i^{(k)}\| = \beta_{k+1} \|e_k^T y_i^{(k)}\|$$

Lemma (a)

□

diskretet: je-lie $\beta_{k+1} \|e_k^T y_i^{(k)}\|$ male, für
s. r. t. A, hier je obige approximation
 Ribe. Esse $\alpha_i^{(k)}$